

Densidad y agrupamiento en movilidad urbana

Semana 8 · GMM, KDE y DBSCAN · 14–18 de septiembre de 2026

Tabla de contenidos

- 1 Pregunta, datos y representación
- 2 Prerrequisitos y notación
- 3 GMM: un modelo probabilístico con variables latentes
- 4 KDE: una densidad sin componentes paramétricas fijas
- 5 DBSCAN: de vecindades a componentes conectadas
- 6 Refuerzo: particiones y jerarquías
- 7 Validación y comunicación sin etiquetas
- 8 Lecturas y procedencia

1 Pregunta, datos y representación

Un equipo de movilidad dispone de ubicaciones de recogida, pero no de etiquetas que identifiquen grupos. Quiere explorar concentraciones espaciales y proponer zonas para un estudio operativo posterior. La pregunta cambia según el objeto que se quiera estimar: una partición, una densidad o una estructura conectada.

El archivo suministrado contiene 200.000 viajes de 2009–2015. Su nombre no permite verificar proveedor ni licencia. El caso utiliza recogidas de 2014 dentro de un rectángulo de estudio de Nueva York. El original se conserva; la auditoría registra exclusiones y la transformación espacial queda documentada.

Cada observación $x_i \in \mathbb{R}^2$ contiene este y norte relativos, en kilómetros. Transformamos WGS84 a UTM 18N (EPSG:32618) y restamos el origen fijo (585000, 4510000) metros antes de dividir por 1000. La traslación facilita lectura y cálculos sin cambiar distancias. No estandarizamos cada eje por separado: eso cambiaría la geometría física. La distancia recta tampoco equivale a distancia vial.

La muestra de desarrollo contiene 6.000 recogidas seleccionadas con semilla 42 de enero–septiembre. Octubre–diciembre contiene 7.311 observaciones reservadas para evaluación temporal. No usamos el test para elegir componentes ni ancho de banda. DBSCAN y jerárquico describen el conjunto que reciben; no tienen aquí una regla de predicción para nuevos viajes.

Qué se puede concluir. Una densidad describe la distribución de las recogidas observadas. No identifica por sí sola volúmenes totales, demanda insatisfecha, cantidad de vehículos o estaciones óptimas. Una agrupación es una representación dependiente de las variables y del método; no prueba barrios verdaderos.

2 Prerrequisitos y notación

Una densidad $f(x)$ es no negativa e integra uno. En variables continuas, la probabilidad de una ubicación exacta es cero; para una región A , $P(X \in A) = \int_A f(x) dx$. La altura de una densidad puede superar uno. En este caso tiene unidades km^{-2} , mientras la masa de una región es adimensional.

Para media $\mu \in \mathbb{R}^d$ y covarianza definida positiva Σ , la normal multivariada es

$$\phi(x; \mu, \Sigma) = (2\pi)^{-d/2} |\Sigma|^{-1/2} \exp \left[-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right].$$

Los autovectores de Σ dan las direcciones principales; los autovalores, la dispersión en esas direcciones. En 2D, el contorno $(x - \mu)^T \Sigma^{-1} (x - \mu) = 5.991$ encierra el 95 % de la masa de esa componente normal. No es un intervalo de confianza de su media ni un contorno del 95 % de la mezcla completa.

Si asumimos observaciones independientes bajo el modelo, la verosimilitud es $L(\theta) = \prod_i f_\theta(x_i)$ y su logaritmo $\ell(\theta) = \sum_i \log f_\theta(x_i)$. Los viajes pueden tener dependencia temporal o espacial; este supuesto de trabajo y la evaluación temporal limitan la interpretación inferencial de los criterios.

Diagnóstico previo. Explique qué ocurre con distancias si un eje está en metros y otro en kilómetros; calcule la media y covarianza de tres puntos; distinga $p(z = k \mid x)$ de $f(x)$; escriba la probabilidad de una región.

3 GMM: un modelo probabilístico con variables latentes

3.1 Modelo generativo

Primero se sortea $z_i \sim \text{Categorical}(\pi_1, \dots, \pi_K)$; después, $x_i \mid z_i = k \sim \mathcal{N}(\mu_k, \Sigma_k)$. Por la ley de probabilidad total,

$$f_\theta(x_i) = \sum_{k=1}^K \pi_k \phi(x_i; \mu_k, \Sigma_k), \quad \pi_k > 0, \quad \sum_k \pi_k = 1.$$

Los pesos representan masa de componentes; no son proporciones administrativas. Varias componentes pueden aproximar una sola región curvada. Permutar los índices de las componentes no cambia la densidad.

Si conociéramos z , ajustaríamos cada normal con sus observaciones. Como no lo conocemos, el logaritmo de una suma dificulta maximizar directamente la verosimilitud observada:

$$\ell(\theta) = \sum_i \log \left[\sum_k \pi_k \phi(x_i; \mu_k, \Sigma_k) \right].$$

3.2 Paso E: responsabilidades mediante Bayes

En la iteración t calculamos

$$r_{ik}^{(t)} = P(z_i = k \mid x_i, \theta^{(t)}) = \frac{\pi_k^{(t)} \phi(x_i; \mu_k^{(t)}, \Sigma_k^{(t)})}{\sum_j \pi_j^{(t)} \phi(x_i; \mu_j^{(t)}, \Sigma_j^{(t)})}.$$

Para cada i , $\sum_k r_{ik} = 1$. Una responsabilidad de 0.55 significa pertenencia condicional bajo este modelo; no probabilidad de que la ubicación sea normal. Un punto lejano puede tener casi toda su responsabilidad en una componente y, simultáneamente, una densidad minúscula.

La entropía $H_i = -\sum_k r_{ik} \log r_{ik}$ resume ambigüedad de pertenencia: va de cero a $\log K$. Para comparar distintos K conviene considerar también $H_i / \log K$ cuando $K > 1$.

3.3 Paso M: maximización ponderada

La esperanza de la log-verosimilitud completa, omitiendo constantes independientes de los parámetros, es

$$Q(\theta \mid \theta^{(t)}) = \sum_{i,k} r_{ik}^{(t)} \left[\log \pi_k - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k) \right].$$

Defina $N_k = \sum_i r_{ik}^{(t)}$. Para los pesos, el lagrangiano incorpora $\lambda(\sum_k \pi_k - 1)$. De $N_k / \pi_k + \lambda = 0$ y $\sum_k N_k = n$ se obtiene

$$\pi_k^{(t+1)} = N_k / n.$$

Para la media, anular $\sum_i r_{ik} \Sigma_k^{-1} (x_i - \mu_k)$ produce

$$\mu_k^{(t+1)} = \frac{1}{N_k} \sum_i r_{ik}^{(t)} x_i.$$

Para la covarianza, escriba $S_k = \sum_i r_{ik} (x_i - \mu_k^{(t+1)}) (x_i - \mu_k^{(t+1)})^T$. La parte relevante es $-N_k \log |\Sigma_k| / 2 - \text{tr}(\Sigma_k^{-1} S_k) / 2$. Derivar respecto de la precisión Σ_k^{-1} da $N_k \Sigma_k / 2 - S_k / 2 = 0$, por tanto

$$\Sigma_k^{(t+1)} = S_k / N_k.$$

El denominador es N_k , no $N_k - 1$: estamos calculando un estimador de máxima verosimilitud ponderado. La media utilizada en S_k es la recién actualizada.

3.4 Por qué EM mejora y qué no garantiza

Para una distribución auxiliar $q(z)$, defina $\mathcal{F}(q, \theta) = \mathbb{E}_q[\log p_\theta(X, z)] + H(q)$. Entonces

$$\ell(\theta) = \mathcal{F}(q, \theta) + \text{KL}(q(z) \parallel p_\theta(z \mid X)).$$

El paso E toma $q = p_{\theta^{(t)}}(z \mid X)$ y hace cero la divergencia en el parámetro actual. El paso M maximiza $\mathcal{F}$ respecto de θ . Como KL es no negativa,

$$\ell(\theta^{(t+1)}) \geq \mathcal{F}(q^{(t)}, \theta^{(t+1)}) \geq \mathcal{F}(q^{(t)}, \theta^{(t)}) = \ell(\theta^{(t)}).$$

Esta es la propiedad de EM exacto. No demuestra óptimo global, unicidad de parámetros ni convergencia útil si aparece una singularidad. En mezclas gaussianas sin restricciones, una componente puede colapsar sobre un punto y hacer crecer la verosimilitud sin cota. La implementación práctica añade una pequeña diagonal a la covarianza y usa varias inicializaciones; esa modificación no debe confundirse con el EM exacto de la prueba.

3.5 Complejidad y selección

Con d variables, el número de parámetros libres es

$$p_{\text{full}} = (K - 1) + Kd + K \frac{d(d+1)}{2}, \quad p_{\text{diag}} = (K - 1) + 2Kd.$$

$$\text{AIC} = -2\ell(\hat{\theta}) + 2p, \quad \text{BIC} = -2\ell(\hat{\theta}) + p \log n.$$

Se prefiere menor valor sobre las mismas observaciones y transformación. No se comparan BIC de muestras distintas como si fueran equivalentes. Las mezclas y la dependencia de datos requieren cautela respecto de las justificaciones asintóticas usuales. En clase se emplea BIC como criterio de selección entre candidatos.

Probamos K de 1 a 8, covarianzas completas y diagonales y cinco inicializaciones. Un mínimo en $K=8$ indica que no se encontró un mínimo interior, no que existan exactamente ocho zonas. Solo tras congelar la elección calculamos log-densidad media en octubre-diciembre, también desglosada por mes.

Ejercicio manual. Para $x = (-2, -1, 1, 2)$, $\pi = (0.5, 0.5)$, $\mu = (-1, 1)$ y varianzas unitarias, calcule un paso E y un paso M. Verifique suma de responsabilidades, simetría de medias y mejora de la función objetivo.

4 KDE: una densidad sin componentes paramétricas fijas

4.1 Construcción y normalización

Sea K un kernel no negativo con integral uno. Para ancho escalar $h > 0$,

$$\hat{f}_h(x) = \frac{1}{nh^d} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right).$$

La integral del término $h^{-d}K((x - x_i)/h)$ se convierte, con $u = (x - x_i)/h$, en $\int K(u) du = 1$. Promediar n contribuciones mantiene la normalización. Para ancho matricial H definido positivo, el factor pasa a ser $|H|^{-1/2}$ y el argumento es $H^{-1/2}(x - x_i)$.

Con kernel normal y ancho escalar, KDE es una mezcla de n normales: peso $1/n$, media fijada en cada dato y covarianza $h^2 I$. En GMM, las medias, covarianzas y pesos se estiman; en KDE se fijan los centros y se elige el suavizado. KDE no devuelve automáticamente etiquetas de grupo.

4.2 Sesgo y varianza: derivación unidimensional

Suponga observaciones i.i.d., kernel simétrico con segundo momento finito $\mu_2(K) = \int u^2 K(u) du$, y densidad dos veces diferenciable en un punto interior. Entonces

$$\mathbb{E}[\hat{f}_h(x)] = \int K(u) f(x - hu) du.$$

Una expansión de Taylor da $f(x - hu) = f(x) - hu f'(x) + h^2 u^2 f''(x)/2 + o(h^2)$. La simetría elimina el término lineal y resulta

$$\text{Bias}[\hat{f}_h(x)] \approx \frac{h^2}{2} \mu_2(K) f''(x).$$

Por independencia y cambio de variable,

$$\text{Var}[\hat{f}_h(x)] = \frac{1}{nh^2} \text{Var} \left[K \left(\frac{x - X}{h} \right) \right] \approx \frac{f(x) R(K)}{nh}, \quad R(K) = \int K(u)^2 du.$$

Integrando el error cuadrático obtenemos la aproximación

$$\text{AMISE}(h) = \frac{h^4}{4} \mu_2(K)^2 R(f'') + \frac{R(K)}{nh}.$$

En d dimensiones, bajo condiciones análogas, su estructura es $Ah^4 + B/(nh^d)$. Al derivar e igualar a cero,

$$4Ah^3 - \frac{dB}{nh^{d+1}} = 0 \implies h_{\text{óptimo}} \propto n^{-1/(d+4)}.$$

La tasa del error es $n^{-4/(d+4)}$: al crecer d , aumentar n rinde menos. Los supuestos importan: bordes, soporte irregular y dependencia pueden modificar estos resultados. No aplicamos una regla asintótica como garantía automática para calles, ríos o periodos distintos.

4.3 Selección y lectura espacial

Probamos anchos 0.1, 0.2, 0.4, 0.8, 1.6 y 3.2 km con kernel gaussiano. Tres folds temporales expansivos comparan log-densidad media en el bloque posterior. El modelo de cada fold usa solo su pasado. Después se reajusta el ancho elegido con toda la muestra de desarrollo y se abre el test una sola vez.

Epanechnikov se utiliza para contrastar forma y soporte: puede dar densidad cero fuera de sus vecindades y log-densidad $-\infty$. No se reemplaza ese resultado por un cero artificial. La selección principal permanece en la familia gaussiana acordada.

Para una región A , aproximamos $\int_A \hat{f}_h(x) dx$ mediante cuadratura. No se suman sin más las alturas de una rejilla: se necesitan sus áreas o una regla de integración. Una KDE normal asignará algo de masa sobre agua y fuera del rectángulo; recortar una imagen no renormaliza la densidad ni corrige fronteras geográficas.

En SVM, el kernel representa productos internos o similitud en un espacio de características para una tarea supervisada. En KDE distribuye masa alrededor de observaciones para estimar una densidad. Compartir la forma gaussiana no hace iguales a ambos procedimientos.

Ejercicio manual. Con datos $(-1, 0, 1)$, calcule la KDE gaussiana en cero para $h=0.5, 1$ y 2 . Explique cómo verificar numéricamente su integral y por qué el valor en cero no es $P(X = 0)$.

5 DBSCAN: de vecindades a componentes conectadas

5.1 Definiciones

Fijados $\varepsilon > 0$ y $m \geq 1$,

$$N_\varepsilon(p) = \{q : d(p, q) \leq \varepsilon\}.$$

Un punto p es **núcleo** si $|N_\varepsilon(p)| \geq m$. La vecindad incluye p . Un punto q es **directamente alcanzable por densidad desde p** si $q \in N_\varepsilon(p)$ y p es núcleo. Esta relación puede ser asimétrica: un núcleo alcanza a una frontera, pero la frontera no expande vecindades.

q es **alcanzable por densidad desde p** si existe una cadena $p = p_1, \dots, p_r = q$ en la que cada p_{j+1} es directamente alcanzable desde p_j . Todos los puntos intermedios que expanden la cadena deben ser núcleo. p y q están **conectados por densidad** si existe o desde el cual ambos son alcanzables.

Un punto no núcleo situado en la vecindad de algún núcleo es **frontera**. Un punto que no es núcleo ni frontera es **ruido**, codificado como -1 en scikit-learn. Esta etiqueta se refiere a una escala y muestra concretas.

5.2 Algoritmo como grafo

1. Calcular vecindades e identificar núcleos.
2. Construir el grafo cuyos vértices son núcleos, con arista entre núcleos a distancia no mayor que ε .
3. Encontrar componentes conexas de ese grafo.
4. Añadir puntos frontera adyacentes; marcar el resto como ruido.

Si una frontera toca dos componentes de núcleos, no las fusiona. Su asignación puede depender del orden de recorrido. Las componentes de núcleos están determinadas por el conjunto y los parámetros; los números de etiqueta son arbitrarios. El diámetro de un grupo puede superar ampliamente ε mediante cadenas de núcleos.

Ejercicio manual. $A=0, B=0.1, C=0.2, D=0.3$ y $E=0.8$, con $\text{eps}=0.115$ y $m=3$. Construya las cinco vecindades, clasifique puntos y dibuje el grafo de núcleos. Cambie m a 2 y explique el efecto.

5.3 Densidad aproximada y escala muestral

En 2D euclidiana, un estimador de conteo en una bola es

$$\hat{f}_\varepsilon(x) \approx \frac{|N_\varepsilon(x)|}{n\pi\varepsilon^2}.$$

La regla de núcleo equivale a superar aproximadamente $m/(n\pi\varepsilon^2)$. Con n menor y m fijo, el umbral aumenta. Reducir m proporcionalmente puede aproximar el umbral anterior, pero no garantiza conectividad ni etiquetas iguales. El autoconteo y el pequeño tamaño local también afectan la aproximación. Una única escala

suele tener dificultades con densidades muy heterogéneas.

En `kneighbors(x)`, al pasar X explícitamente, se incluye el propio punto a distancia cero. Para m vecinos, se inspecciona la columna $m-1$. Una curva ordenada ayuda a proponer ϵ , pero no constituye una prueba de optimalidad.

El experimento usa ϵ entre 0.1 y 1.6 km y m en $\{5, 15, 30\}$. Se documentan grupos, tamaños, ruido, mapas y sensibilidad. «Todo ruido» y «un grupo» son resultados posibles. No se aumenta ϵ solo para obtener un mapa visualmente satisfactorio. Para grandes muestras, vecindades densas pueden exigir memoria cuadrática; la muestra fija limita ese costo en clase.

6 Refuerzo: particiones y jerarquías

6.1 K-means y Lloyd

$$J(z, \mu) = \sum_{k=1}^K \sum_{i: z_i=k} \|x_i - \mu_k\|^2.$$

Fijados centros, cada punto elige el más cercano. Fijadas asignaciones, $\nabla_{\mu_k} J = 2n_k \mu_k - 2 \sum_{i: z_i=k} x_i = 0$, de modo que el centro es la media. La alternancia no aumenta J , pero puede terminar en mínimos locales. Varias inicializaciones ayudan. Todos los puntos reciben etiqueta; la función objetivo es sensible a extremos y a escala.

Con pesos iguales y covarianzas comunes $\sigma^2 I$, la asignación de máxima responsabilidad de GMM coincide con centro más cercano. Cuando $\sigma^2 \rightarrow 0$, las responsabilidades se endurecen salvo empates. La conexión no implica equivalencia de K-means con un GMM general.

Ejercicio: datos 0,1,4,5 y centros iniciales 0,4. Dos iteraciones, centros finales e inercia.

6.2 Jerárquico y Ward

El método aglomerativo empieza con un grupo por dato y fusiona. El divisivo empieza con un grupo y separa. Los enlaces simple, completo y promedio usan, respectivamente, mínimo, máximo y media de las distancias entre pares de puntos de grupos diferentes. El enlace simple puede encadenar grupos por puentes de puntos.

Para Ward, sean n_A, n_B los tamaños y μ_A, μ_B las medias. La media conjunta es $\mu = (n_A \mu_A + n_B \mu_B) / (n_A + n_B)$. Descomponer cada suma de cuadrados respecto de su propia media da

$$\text{SSE}(A \cup B) = \text{SSE}(A) + \text{SSE}(B) + n_A \|\mu_A - \mu\|^2 + n_B \|\mu_B - \mu\|^2.$$

Al sustituir la media conjunta,

$$\Delta(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mu_A - \mu_B\|^2.$$

Ward elige el menor incremento. Requiere la geometría euclidiana de esta identidad; no se combina sin justificación con haversine. SciPy representa la altura de enlace como $\sqrt{2\Delta}$. La altura es el criterio de enlace, no necesariamente una distancia entre centroides; la posición horizontal del dendrograma es un orden de hojas. Un corte selecciona una resolución, no una verdad natural.

Ejercicio: $A=\{0,2\}$ y $B=\{5\}$. Calcule la media conjunta, SSE antes y después, incremento Ward y altura SciPy.

7 Validación y comunicación sin etiquetas

Para cada punto asignado, silhouette compara distancia media dentro del grupo $a(i)$ con la menor distancia media a otro grupo $b(i)$: $s(i) = (b(i) - a(i)) / \max(a(i), b(i))$. Requiere entre 2 y $n-1$ grupos. Para un grupo de un solo punto se usa la convención de silhouette cero. Favorece ciertas geometrías compactas; no certifica estructura real.

En DBSCAN se excluye ruido del cálculo y se reporta la fracción cubierta. Comparar puntuaciones sobre subconjuntos distintos no es una comparación controlada. Si el cálculo no está definido se registra NaN, sin reemplazarlo por cero. Para jerárquico y K-means, la comparación usa los mismos 500 puntos.

Davies–Bouldin compara dispersión interna y separación de centroides; menor es mejor bajo ese criterio. También favorece estructuras representables por centros. Lo dejamos como extensión para la semana siguiente, junto con estabilidad por remuestreo. Esta semana prioriza sensibilidad y lectura contextual.

La selección de GMM/KDE y el clustering responden preguntas distintas. La log-densidad temporal compara modelos de densidad sobre las mismas observaciones y unidades; no sirve para ordenar directamente DBSCAN y K-means. Los identificadores de grupo pueden permutarse sin alterar la solución; no se mide estabilidad comparando números de etiqueta punto a punto.

Cierre: escriba una recomendación de cinco a ocho líneas: qué observa, qué interpretación permite el modelo, qué estudiaría, qué vigilaría y qué no puede concluir. Una recomendación válida puede ser recolectar datos adicionales antes de elegir zonas operativas.

8 Lecturas y procedencia

- Microcurrículo ML2 y guía docente suministrados, sesiones 19–24. El calendario de este paquete implementa el ajuste acordado: una sesión por tema, semana 8, 14–18 de septiembre.
- Cuaderno histórico del docente, *Detección de Fraude*: inspiración de actividades de K-means, jerárquico y DBSCAN, con corrección de objetivo y reglas de asignación. El caso nuevo utiliza movilidad.
- [scikit-learn: Gaussian mixture models](#).
- [scikit-learn: Density estimation](#).
- [scikit-learn: Clustering](#).
- [SciPy: linkage](#).
- Datos: CSV suministrado por el docente, huella y auditoría en [datasets/semana-08/manifest.json](#). No se asigna una licencia no verificada ni se atribuyen registros a una plataforma basándose en el nombre.